



HYBRID SEARCH

Kết hợp Keyword Search, Semantic Search
và Reciprocal Rank Fusion

Instructor(s): PGS.TS Thoai Nam

Student(s):

Duong Gia An — 2470293

Trinh Son Lam — 2470287

Nguyen Thanh Huyen — 2570416

Đại học Bách khoa TP.HCM — Khoa KH & KT Máy tính — CO5135 — Big Data (HK252)

Tháng 5, 2026

- 1 Bài toán tìm kiếm (Information Retrieval)
- 2 Tìm kiếm từ khóa (Keyword Search)
- 3 Tìm kiếm ngữ nghĩa (Semantic Search)
- 4 Tìm kiếm kết hợp (Hybrid Search)
- 5 Nghiên cứu thực tế (Case Studies)
- 6 Kết luận & Xu hướng

Thực trạng

Mỗi ngày thế giới tạo ra **2.5 quintillion bytes** dữ liệu. Phần lớn là **phi cấu trúc**: văn bản, ảnh, video, bài báo...

Các kho dữ liệu lớn:

- **Google**: 130+ nghìn tỷ trang web
- **arXiv**: 2.4+ triệu bài báo
- **Wikipedia**: 60+ triệu bài viết

⇒ **Information Retrieval (IR)**: tìm kiếm thông tin liên quan trong dữ liệu lớn.

IR Pipeline chuẩn

- 1 **Ingestion**: Thu thập, làm sạch
- 2 **Indexing**: Cấu trúc tra cứu nhanh
- 3 **Retrieval**: Nhận query, xếp hạng

Ba thế hệ tìm kiếm

- 1 **Lexical** (1970s): Đối khớp từ khóa
 - 2 **Semantic** (2018): Hiểu ngữ nghĩa (AI)
- ★ **Hybrid** (2022+): Kết hợp cả hai!

Ý tưởng: Thay vì quét toàn bộ tài liệu, xây dựng **bảng tra cứu ngược**:

Forward Index (quét tuần tự)

Doc	Nội dung
D_1	deep learning for NLP
D_2	deep neural networks
D_3	NLP with transformers

→ Quét tuần tự → $O(N)$

Inverted Index (tra ngược)

Term	Posting List
deep	$[D_1, D_2]$
learning	$[D_1]$
NLP	$[D_1, D_3]$
neural	$[D_2]$
transformers	$[D_3]$

→ Tra bảng ngay → $O(1)$ lookup!

Ai dùng?

Google, Elasticsearch, Apache Solr, Lucene, Bing, Wikipedia, Stack Overflow...

Công thức BM25 (Robertson & Zaragoza, 2009)

$$\text{BM25}(D, Q) = \sum_{i=1}^n \underbrace{\text{IDF}(q_i)}_{\text{Từ hiếm} \rightarrow \text{quan trọng}} \cdot \frac{\overbrace{f(q_i, D)}^{\text{Term Freq}} \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

Ba yếu tố quyết định:

- **TF**: Xuất hiện nhiều $\rightarrow$ bão hòa
- **IDF**: Từ hiếm $\rightarrow$ trọng số cao. VD: “transformer” $\gg$ “the”
- **Doc Length**: Tài liệu dài bị phạt

Tham số chuẩn: $k_1 = 1.2$, $b = 0.75$

Dùng ở đâu?

ES, OpenSearch, Solr, Lucene, SQLite FTS5. Mặc định cho keyword search.

Hạn chế cốt lõi

BM25 chỉ hiểu từ vựng, không hiểu ngữ nghĩa:

- “car” $\neq$ “automobile”
- “detect fake images” $\neq$ “deepfake”


Ý tưởng: Biểu diễn ý nghĩa văn bản bằng vector. Các văn bản tương đồng ngữ nghĩa $\rightarrow$ vector gần nhau.

Lịch sử phát triển

- 1 **Word2Vec** (2013): Mỗi từ $\rightarrow$ 1 vector.
- 2 **BERT** (2018): Hiểu ngữ cảnh. “bank” (ngân hàng) $\neq$ “bank” (bờ sông)
- 3 **Sentence Transformers** (2019): Mỗi câu $\rightarrow$ 1 vector. Tối ưu cho search.

Cosine Similarity:

$$\cos(\vec{a}, \vec{b}) = \frac{\vec{a} \cdot \vec{b}}{\|\vec{a}\| \cdot \|\vec{b}\|} \in [-1, 1]$$



Ứng dụng thực tế

Google Search, Spotify (gợi nhạc), Netflix, Airbnb, RAG pipelines (ChatGPT + retrieval)

Embedding Models phổ biến

Model	Dims	MTEB	Ghi chú
MiniLM-L6-v2	384	56	Nhẹ, nhanh
bge-small-v1.5	384	62	BAAI
e5-large-v2	1024	64	Microsoft
text-embed-3-large	3072	65	OpenAI API
SPECTER2	768	—	Academic

Cosine Similarity thực tế

Cặp câu	Cosine
fake images ↔ image forgery	0.70
car ↔ automobile	0.78
bank (tiền) ↔ bank (sông)	0.35

Đặc trưng cốt lõi:

- **Trade-off**: Kích thước vector lớn → biểu diễn ngữ nghĩa tốt hơn nhưng tốn RAM và băng thông.
- **MTEB**: Bảng xếp hạng chuẩn đánh giá chất lượng mô hình nhúng.

Tìm kiếm chính xác: $O(N \cdot d)$ quá chậm!

$N=1M$ văn bản, $d=384$ chiều $\rightarrow$ **384 triệu phép tính** cho mỗi truy vấn!

- Phép quét tuyến tính (Exact brute-force kNN)
- Không khả thi đối với dữ liệu lớn (Big Data)

Giải pháp: Tìm kiếm xấp xỉ (ANN)

Chấp nhận kết quả lảng giềng gần đúng để đổi lấy tốc độ truy xuất cực nhanh ($O(N) \rightarrow O(\log N)$).

Các thuật toán tìm kiếm xấp xỉ

Thuật toán	Ý tưởng	Dùng bởi
LSH	Hash function	Uber
IVF	K-Means clusters	FAISS (Meta)
HNSW	Đồ thị đa tầng	Elasticsearch
ScaNN	Quantization	Google

HNSW (Malkov & Yashunin, 2018):

- Đồ thị đa tầng tương tự Skip List: lớp trên nhảy xa định vị nhanh, lớp dưới chi tiết dần.
- Dùng mặc định trong Elasticsearch, Pinecone, Qdrant.

Tại sao cần Hybrid Search?

Tìm kiếm kết hợp (Hybrid Search)

Tìm kiếm từ khóa (Keyword Search)

Giải:

- Thuật ngữ chính xác: “ResNet-50”
- Tên riêng, mã, viết tắt
- Nhanh, nhẹ tài nguyên

Yếu:

- car $\neq$ automobile
- “detect fake images” $\neq$ “deepfake”

Tìm kiếm ngữ nghĩa (Semantic Search)

Giải:

- Hiểu paraphrase, đồng nghĩa
- Query ngôn ngữ tự nhiên
- Cross-lingual (đa ngôn ngữ)

Yếu:

- Viết tắt chuyên ngành, exact match
- Tốn RAM, GPU, index lớn

⇒ **Hybrid Search = Kết hợp cả hai bằng Rank Fusion**

Đang được dùng bởi: Elasticsearch 8.x, Azure AI Search, Pinecone, Weaviate, Vespa, Qdrant, Google Vertex AI Search, Amazon OpenSearch

Score-level (cần normalize)

Weighted Linear Combination:

$$S(d) = \alpha \cdot S_{\text{Keyword}} + (1-\alpha) \cdot S_{\text{Semantic}}$$

- Phải normalize score (khác thang)
- Phải tune α (thường 0.3–0.7)
- Nhạy cảm với phân phối

CombSUM / CombMNZ: Cộng/nhân score

Rank-level (không cần normalize)

Reciprocal Rank Fusion (RRF):

$$RRF(d) = \sum_{r \in R} \frac{1}{k + \text{rank}_r(d)}$$

- Chỉ dùng **thứ hạng**, bỏ qua score
- Không cần normalize — Điểm số từ khóa (0–30) và điểm số ngữ nghĩa (0–1) đều OK
- $k = 60$ (Cormack et al., SIGIR 2009)
- **Parameter-free** — không tune α

RRF là mặc định trong Elasticsearch 8.x, Azure AI Search.

Query: “transformer architecture for NLP tasks”

Keyword Top-5

Rank	Doc
1	D_A
2	D_B
3	D_C
4	D_D
5	D_E

Semantic Top-5

Rank	Doc
1	D_C
2	D_A
3	D_F
4	D_B
5	D_G

RRF Merge ($k = 60$)

#	Doc	RRF Score
1	D_A	$\frac{1}{61} + \frac{1}{62} = 0.0325$
2	D_C	$\frac{1}{63} + \frac{1}{61} = 0.0323$
3	D_B	$\frac{1}{62} + \frac{1}{64} = 0.0318$
4	D_F	$\frac{1}{63} = 0.0159$

Doc xuất hiện top ở CẢ HAI danh sách → RRF score cao nhất.

D_F, D_G chỉ nằm trong 1 danh sách → score thấp hơn.

Case Study 1: E-commerce Search (Shopee, Amazon) Nghiên cứu thực tế (Case Studies)

Bối cảnh

Một sàn thương mại điện tử có **hàng trăm triệu** sản phẩm. Người dùng search rất đa dạng:

Nhóm 1 — Exact:

“iPhone 15 Pro Max 256GB”

→ Keyword Search khớp mã sản phẩm

Nhóm 2 — Semantic:

“quà sinh nhật cho bạn gái”


→ Không khớp từ khóa nào! Cần Semantic Search hiểu ý và gợi ý quà tặng...

Nhóm 3 — Mixed:

“áo khoác chống nước đi mưa”

→ Keyword khớp “áo khoác”, Semantic hiểu “chống nước” $\approx$ “waterproof”

Kiến trúc Hybrid Search



Kết quả (industry reports)

- Conversion rate tăng **15–25%**
- Zero-result queries giảm **40–60%**

Bối cảnh tương tự

1.2 triệu bài báo CS từ arXiv. Cùng 3 loại query:

Exact: "BERT fine-tuning"

Semantic: "methods to detect fake images"

Mixed: "transformer for NLP tasks"

Kết quả NDCG@10 (30 queries)

	Exact	Sem.	Mixed
Từ khóa (BM25)	0.64	0.68	0.70
Ngữ nghĩa (kNN)	0.66	0.66	0.68
Kết hợp (Hybrid)	0.98	0.95	0.98

So sánh với E-commerce

Khía cạnh	E-commerce	Academic
Quy mô	100M+	1.2M
Query	đa dạng	chuyên ngành
Embedding	product desc	title+abstract
Metric	CTR, CVR	NDCG, MRR

Key Insight

Overlap (Keyword $\cap$ Semantic) chỉ **1.5/10**

→ Hai phương pháp tìm kết quả **rất khác nhau**

→ Hybrid kết hợp cả hai → NDCG tăng từ ~ 0.67 lên ~ 0.97

Tech: ES 8.12, MiniLM-L6-v2, RRF $k=60$, FastAPI, React

1. Keyword $\neq$ Semantic

Hai paradigm **bổ sung nhau**, không thay thế. Tìm kiếm từ khóa giải exact terms, tìm kiếm ngữ nghĩa giải paraphrase.

2. RRF: Đơn giản, hiệu quả

Parameter-free, không cần normalize. Là mặc định của Elasticsearch, Azure AI Search.

3. Tìm kiếm xấp xỉ giải bài toán scale

HNSW, IVF, ScaNN biến đổi $O(N) \rightarrow O(\log N)$, hỗ trợ tìm kiếm trên hàng triệu—tỷ vectors.

Xu hướng 2024–2026

- **RAG: Hybrid Search + LLM**
→ ChatGPT trả lời từ dữ liệu riêng
- **Multi-stage Retrieval:**
Hybrid (fast) → Cross-Encoder (accurate)
- **Learned Sparse: SPLADE, ColBERT**
→ Kết hợp sparse + dense trong 1 model
- **Multimodal Search:**
Text + image + audio cùng lúc
- **Vector Databases:**
Pinecone, Weaviate, Qdrant, Milvus

Hybrid Search là **kiến trúc nền tảng** cho thế hệ ứng dụng AI tiếp theo.

Cảm ơn!

Q & A

Hybrid Search: Keyword + Semantic + Rank Fusion

Group 11 — CO5135 Big Data — HCMUT, HK252

Source: <https://github.com/kinggiaan/Big-Data>