



HYBRID SEARCH

Kết hợp Keyword Search, Semantic Search
và Reciprocal Rank Fusion

Instructor(s): PGS.TS Thoai Nam

Student(s):

Duong Gia An — 2470293

Trinh Son Lam — 2470287

Nguyen Thanh Huyen — 2570416

Đại học Bách khoa TP.HCM — Khoa KH & KT Máy tính — CO5135 — Big Data (HK252)

Tháng 5, 2026

Nội dung trình bày

- 1 Bài toán tìm kiếm (Information Retrieval)
- 2 Tìm kiếm từ khóa (Keyword Search)
- 3 Tìm kiếm ngữ nghĩa (Semantic Search)
- 4 Tìm kiếm kết hợp (Hybrid Search)
- 5 Nghiên cứu thực tế (Case Studies)
- 6 Kết luận & Xu hướng

Thực trạng

Mỗi ngày thế giới tạo ra **2.5 quintillion bytes** dữ liệu. Phần lớn là **phi cấu trúc**: văn bản, ảnh, video, bài báo...

Các kho dữ liệu lớn:

- **Google**: 130+ nghìn tỷ trang web
- **arXiv**: 2.4+ triệu bài báo
- **Wikipedia**: 60+ triệu bài viết

⇒ **Information Retrieval (IR)**: tìm kiếm thông tin liên quan trong dữ liệu lớn.

IR Pipeline chuẩn

- 1 **Ingestion**: Thu thập, làm sạch
- 2 **Indexing**: Cấu trúc tra cứu nhanh
- 3 **Retrieval**: Nhận query, xếp hạng

Ba thế hệ tìm kiếm

- 1 **Lexical** (1970s): Đối khớp từ khóa
- 2 **Semantic** (2018): Hiểu ngữ nghĩa (AI)
- ★ **Hybrid** (2022+): Kết hợp cả hai!

Ý tưởng: Thay vì quét toàn bộ tài liệu, xây dựng **bảng tra cứu ngược**:

Forward Index (quét tuần tự)

Doc	Nội dung
D_1	deep learning for NLP
D_2	deep neural networks
D_3	NLP with transformers

→ Quét tuần tự → $O(N)$

Inverted Index (tra ngược)

Term	Posting List
deep	$[D_1, D_2]$
learning	$[D_1]$
NLP	$[D_1, D_3]$
neural	$[D_2]$
transformers	$[D_3]$

→ Tra bảng ngay → $O(1)$ lookup!

Ai dùng?

Google, Elasticsearch, Apache Solr, Lucene, Bing, Wikipedia, Stack Overflow...

Công thức BM25 (Robertson & Zaragoza, 2009)

$$\text{BM25}(D, Q) = \sum_{i=1}^n \underbrace{\text{IDF}(q_i)}_{\text{Từ hiếm} \rightarrow \text{quan trọng}} \cdot \frac{\overbrace{f(q_i, D)}^{\text{Term Freq}} \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

Ba yếu tố quyết định:

- **TF**: Xuất hiện nhiều $\rightarrow$ bão hòa
- **IDF**: Từ hiếm $\rightarrow$ trọng số cao. VD: “transformer” $\gg$ “the”
- **Doc Length**: Tài liệu dài bị phạt

Tham số chuẩn: $k_1 = 1.2$, $b = 0.75$

Dùng ở đâu?

ES, OpenSearch, Solr, Lucene, SQLite FTS5. Mặc định cho keyword search.

Hạn chế cốt lõi

BM25 chỉ hiểu từ vựng, không hiểu ngữ nghĩa:

- “car” $\neq$ “automobile”
- “detect fake images” $\neq$ “deepfake”


Ý tưởng: Biểu diễn ý nghĩa văn bản bằng vector. Các văn bản tương đồng ngữ nghĩa $\rightarrow$ vector gần nhau.

Lịch sử phát triển

- 1 **Word2Vec** (2013): Mỗi từ $\rightarrow$ 1 vector.
- 2 **BERT** (2018): Hiểu ngữ cảnh. “bank” (ngân hàng) $\neq$ “bank” (bờ sông)
- 3 **Sentence Transformers** (2019): Mỗi câu $\rightarrow$ 1 vector. Tối ưu cho search.

Cosine Similarity:

$$\cos(\vec{a}, \vec{b}) = \frac{\vec{a} \cdot \vec{b}}{\|\vec{a}\| \cdot \|\vec{b}\|} \in [-1, 1]$$



Ứng dụng thực tế

Google Search, Spotify (gợi nhạc), Netflix, Airbnb, RAG pipelines (ChatGPT + retrieval)

Embedding Models phổ biến

Model	Dims	MTEB	Ghi chú
MiniLM-L6-v2	384	56	Nhẹ, nhanh
bge-small-v1.5	384	62	BAAI
e5-large-v2	1024	64	Microsoft
text-embed-3-large	3072	65	OpenAI API
SPECTER2	768	—	Academic

Cosine Similarity thực tế

Cặp câu	Cosine
fake images ↔ image forgery	0.70
car ↔ automobile	0.78
bank (tiền) ↔ bank (sông)	0.35

Đặc trưng cốt lõi:

- **Trade-off**: Kích thước vector lớn → biểu diễn ngữ nghĩa tốt hơn nhưng tốn RAM và băng thông.
- **MTEB**: Bảng xếp hạng chuẩn đánh giá chất lượng mô hình nhúng.

Tìm kiếm chính xác: $O(N \cdot d)$ quá chậm!

$N=1M$ văn bản, $d=384$ chiều $\rightarrow$ **384 triệu phép tính** cho mỗi truy vấn!

- Phép quét tuyến tính (Exact brute-force kNN)
- Không khả thi đối với dữ liệu lớn (Big Data)

Giải pháp: Tìm kiếm xấp xỉ (ANN)

Chấp nhận kết quả lảng giềng gần đúng để đổi lấy tốc độ truy xuất cực nhanh ($O(N) \rightarrow O(\log N)$).

Các thuật toán tìm kiếm xấp xỉ

Thuật toán	Ý tưởng	Dùng bởi
LSH	Hash function	Uber
IVF	K-Means clusters	FAISS (Meta)
HNSW	Đồ thị đa tầng	Elasticsearch
ScaNN	Quantization	Google

HNSW (Malkov & Yashunin, 2018):

- Đồ thị đa tầng tương tự Skip List: lớp trên nhảy xa định vị nhanh, lớp dưới chi tiết dần.
- Dùng mặc định trong Elasticsearch, Pinecone, Qdrant.

Tại sao cần Hybrid Search?

Tìm kiếm kết hợp (Hybrid Search)

Tìm kiếm từ khóa (Keyword Search)

Giải:

- Thuật ngữ chính xác: “ResNet-50”
- Tên riêng, mã, viết tắt
- Nhanh, nhẹ tài nguyên

Yếu:

- car $\neq$ automobile
- “detect fake images” $\neq$ “deepfake”

Tìm kiếm ngữ nghĩa (Semantic Search)

Giải:

- Hiểu paraphrase, đồng nghĩa
- Query ngôn ngữ tự nhiên
- Cross-lingual (đa ngôn ngữ)

Yếu:

- Viết tắt chuyên ngành, exact match
- Tốn RAM, GPU, index lớn

⇒ **Hybrid Search = Kết hợp cả hai bằng Rank Fusion**

Đang được dùng bởi: Elasticsearch 8.x, Azure AI Search, Pinecone, Weaviate, Vespa, Qdrant, Google Vertex AI Search, Amazon OpenSearch

Score-level (cần normalize)

Weighted Linear Combination:

$$S(d) = \alpha \cdot S_{\text{Keyword}} + (1-\alpha) \cdot S_{\text{Semantic}}$$

- Phải normalize score (khác thang)
- Phải tune α (thường 0.3–0.7)
- Nhạy cảm với phân phối

CombSUM / **CombMNZ**: Cộng/nhân score

Rank-level (không cần normalize)

Reciprocal Rank Fusion (RRF):

$$RRF(d) = \sum_{r \in R} \frac{1}{k + \text{rank}_r(d)}$$

- Chỉ dùng **thứ hạng**, bỏ qua score
- Không cần normalize — Điểm số từ khóa (0–30) và điểm số ngữ nghĩa (0–1) đều OK
- $k = 60$ (Cormack et al., SIGIR 2009)
- **Parameter-free** — không tune α

RRF là mặc định trong Elasticsearch 8.x, Azure AI Search.

Query: “transformer architecture for NLP tasks”

Keyword Top-5

Rank	Doc
1	D_A
2	D_B
3	D_C
4	D_D
5	D_E

Semantic Top-5

Rank	Doc
1	D_C
2	D_A
3	D_F
4	D_B
5	D_G

RRF Merge ($k = 60$)

#	Doc	RRF Score
1	D_A	$\frac{1}{61} + \frac{1}{62} = 0.0325$
2	D_C	$\frac{1}{63} + \frac{1}{61} = 0.0323$
3	D_B	$\frac{1}{62} + \frac{1}{64} = 0.0318$
4	D_F	$\frac{1}{63} = 0.0159$

Doc xuất hiện top ở CẢ HAI danh sách → RRF score cao nhất.

D_F, D_G chỉ nằm trong 1 danh sách → score thấp hơn.

Case Study 1: E-commerce Search (Shopee, Amazon) Nghiên cứu thực tế (Case Studies)

Bối cảnh

Một sàn thương mại điện tử có **hàng trăm triệu** sản phẩm. Người dùng search rất đa dạng:

Nhóm 1 — Exact:

“iPhone 15 Pro Max 256GB”

→ Keyword Search khớp mã sản phẩm

Nhóm 2 — Semantic:

“quà sinh nhật cho bạn gái”


→ Không khớp từ khóa nào! Cần Semantic Search hiểu ý và gợi ý quà tặng...

Nhóm 3 — Mixed:

“áo khoác chống nước đi mưa”

→ Keyword khớp “áo khoác”, Semantic hiểu “chống nước” $\approx$ “waterproof”

Kiến trúc Hybrid Search



Kết quả (industry reports)

- Conversion rate tăng **15–25%**
- Zero-result queries giảm **40–60%**

Bối cảnh tương tự

1.2 triệu bài báo CS từ arXiv. Cùng 3 loại query:

Exact: "BERT fine-tuning"

Semantic: "methods to detect fake images"

Mixed: "transformer for NLP tasks"

Kết quả NDCG@10 (30 queries)

	Exact	Sem.	Mixed
Từ khóa (BM25)	0.64	0.68	0.70
Ngữ nghĩa (kNN)	0.66	0.66	0.68
Kết hợp (Hybrid)	0.98	0.95	0.98

So sánh với E-commerce

Khía cạnh	E-commerce	Academic
Quy mô	100M+	1.2M
Query	đa dạng	chuyên ngành
Embedding	product desc	title+abstract
Metric	CTR, CVR	NDCG, MRR

Key Insight

Overlap (Keyword $\cap$ Semantic) chỉ **1.5/10**

→ Hai phương pháp tìm kết quả **rất khác nhau**

→ Hybrid kết hợp cả hai → NDCG tăng từ ~ 0.67 lên ~ 0.97

Tech: ES 8.12, MiniLM-L6-v2, RRF $k=60$, FastAPI, React

1. Keyword $\neq$ Semantic

Hai paradigm **bổ sung nhau**, không thay thế. Tìm kiếm từ khóa giải exact terms, tìm kiếm ngữ nghĩa giải paraphrase.

2. RRF: Đơn giản, hiệu quả

Parameter-free, không cần normalize. Là mặc định của Elasticsearch, Azure AI Search.

3. Tìm kiếm xấp xỉ giải bài toán scale

HNSW, IVF, ScaNN biến đổi $O(N) \rightarrow O(\log N)$, hỗ trợ tìm kiếm trên hàng triệu—tỷ vectors.

Xu hướng 2024–2026

- **RAG: Hybrid Search + LLM**
→ ChatGPT trả lời từ dữ liệu riêng
- **Multi-stage Retrieval:**
Hybrid (fast) → Cross-Encoder (accurate)
- **Learned Sparse: SPLADE, ColBERT**
→ Kết hợp sparse + dense trong 1 model
- **Multimodal Search:**
Text + image + audio cùng lúc
- **Vector Databases:**
Pinecone, Weaviate, Qdrant, Milvus

Hybrid Search là **kiến trúc nền tảng** cho thể hệ ứng dụng AI tiếp theo.

Cảm ơn!

Q & A

Hybrid Search: Keyword + Semantic + Rank Fusion

Group 11 — CO5135 Big Data — HCMUT, HK252

Source: <https://github.com/kinggiaan/Big-Data>

Latency qua các quy mô

Method	100k		500k		1.2M	
	P50	P95	P50	P95	P50	P95
BM25	15	56	21	37	71	153
kNN	13	34	20	41	191	1206
Hybrid	30	53	42	62	99	156

(đơn vị: ms)

- kNN P95=1206ms ở 1.2M: HNSW cold start
- Sau warm cache: Hybrid chỉ **99ms**

Storage Scaling

Scale	Docs	JSONL	ES Index
100k	100K	917 MB	860 MB
500k	500K	4.6 GB	4.3 GB
1.2M	1.2M	12 GB	11.9 GB

- **87%** dung lượng là vector (HNSW graph)
- Tăng trưởng tuyến tính theo docs
- Mỗi vector: $384 \times 4 = 1,536$ bytes

Query: “attention mechanism” Corpus: 1.2M papers

Bước 1: Analyze query

attention mechanism

↓ Analyzer: lowercase → stemming

→ Tokens: [attent, mechan]

Bước 2: Tra Inverted Index

attent → $\{D_{42}, D_{107}, D_{1580}, \dots\}$

mechan → $\{D_{42}, D_{305}, D_{8921}, \dots\}$

Giao tập → $\{D_{42}, \dots\}$

Bước 3: Tính BM25

Với D_{42} (“Attention Is All You Need”):

- $TF(attent, title) = 1$
- $IDF(attent) = 4.2$ (tử hiếm)
- Title boost $\times 2$
- $\Rightarrow \text{Score} = 12.8$

Khi BM25 thất bại

“methods to detect fake images”

→ Không match “deepfake detection”

vì 0 từ khóa chung! Cần Tìm kiếm ngữ nghĩa.